

SemiAnalysis：AI 算力紧缺并未结束，2026 年或再次进入供给瓶颈

原文日期 2026-06-14 文件生成 2026-09-12

[阅读网站原文](#)

离线阅读版保留原文观点与日期，不代表当前判断。来源链接可点击；网页的最新修订以原文为准。

SemiAnalysis 周五向机构客户发布的最新半导体调研报告显示：AI 算力市场并未进入供给过剩阶段，反而在 2026 年初再次出现紧缺现象。

核心观点

- H100 一年期租赁价格从 2025 年 10 月低点 1.7 美元/小时上涨至 2.35 美元/小时，反弹约 40%
- H100/H200 集群普遍售罄
- Blackwell 交付周期延长至 6-7 个月

SemiAnalysis 认为，本轮需求与 2023 年的训练驱动型 GPU 抢购存在本质区别。2023 年的核心需求来自模型训练，而当前需求已逐渐转向 Agent（智能体）和推理（Inference）。随着 AI 开始真正创造收入，Token 成本已经从研发成本转变为生产成本。在这种情况下，企业对于 GPU 价格上涨的敏感度下降，即使 GPU 租赁价格持续上涨，企业仍会继续扩容。

对于半导体产业链：利好 NVDA、AMD（需求外溢）、HBM 存储链（MU、SK 海力士）、高速网络与光互联（MRVL、COHR、LITE 等）。

一、最关键的信息：供给过剩逻辑正在被证伪

过去半年市场一直在交易 AI 资本开支见顶，背后对应的是 GPU 供给过剩、数据中心建设放缓、云厂商采购降温。因此 NVDA、MU、光模块、AI 电力链都出现过明显估值压缩。

SemiAnalysis 此次调研用真实价格和交付周期证明：**GPU 仍然是稀缺资源**。如果租赁价格上涨、交期拉长同时发生，市场最担心的库存积压并未出现。

二、训练时代正在进入推理时代

第一阶段（2023-2025）：市场主要购买 GPU 用于训练模型——一次性投入、项目制需求、容易出现周期波动。

第二阶段（2026 开始）：需求逐渐转向推理和 Agent——持续消耗算力、与用户规模直接挂钩、更接近云计算模式。

训练决定需求的起点，推理决定需求的终点。推理市场的天花板远高于训练市场。

三、为什么 GPU 涨价反而是利好？

传统行业：价格上涨→需求下降。但 AI 行业的逻辑不同——客户计算的是 ROI。如果 100 万美元 GPU 投入能创造 300 万美元收入，那么 GPU 价格上涨 20-30%并不会改变投资决策。

ChatGPT、Claude、Gemini、企业 Agent 开始进入商业化收费阶段后，Token 已经成为收入来源。GPU 不再只是成本中心，而是生产工具。这意味着未来 GPU 的定价权可能比市场想象得更强。

四、产业链受益顺序

第一层：GPU

NVDA、AMD — GPU 需求持续强劲，NVDA 交付周期延长意味着订单可见度提高，AMD 承接需求外溢。

第二层：HBM 存储

MU、SK 海力士 — HBM 已成为 AI 服务器最重要的价值量增长环节。Bernstein 拆解显示 NVL72 机柜内存成本约 320 万美元，占整机柜成本 35%。

第三层：高速互联与光模块

LITE、COHR、MRVL — GPU 数量越多，网络价值量增长越快。从 Blackwell 到 Vera Rubin，单机柜 GPU 数量继续增加，光模块逻辑不限于 800G→1.6T，而是 AI Factory 规模扩张带来的系统性受益。

五、风险点

本报告成立的前提是 AI 应用收入持续增长，需观察：OpenAI 商业化收入、Copilot 企业付费用户增长、Gemini 商业化进展、Agent 部署数量、推理 Token 消费量。如果未来 AI 收入增长明显放缓，GPU 需求扩张逻辑可能受阻。

结论

市场当前仍在担心"AI 资本开支见顶"，而 SemiAnalysis 给出的证据指向相反方向：GPU 租赁价格上涨、集群持续售罄、Blackwell 交期拉长——AI 基础设施建设周期并未结束。

更重要的是，本轮需求驱动力已从训练转向推理与 Agent，AI 算力需求开始具备持续消耗属性。如果这一趋势得到验证，未来几年最值得关注的方向可能不是 GPU 本身，而是 GPU 背后的两大瓶颈：

- HBM 存储 (MU、SK 海力士)
- 光互联与高速网络 (LITE、COHR、MRVL)

2023 年市场买 GPU 是在训练模型；2026 年市场买 GPU 是在运营 AI 业务。前者是资本开支，后者更接近生产资料。一旦这个判断成立，AI 基础设施周期的持续时间就会比市场原先预期长得多，而当前重仓的"存储+光互联"正好位于本轮扩张中最容易形成瓶颈的两个环节。